

지방보조금 부정수급 위험도 측정 시스템

프로젝트 소개 (로컬 웹 서비스)

버전: 2026-07

원칙: 모든 데이터·학습·점수는 사용자 PC 내부(127.0.0.1)에서만 처리됩니다.

1. 프로젝트 개발 목적

1.1 배경

지방보조금 사업은 건수가 많고, 부정수급·오지급 사례는 전체 대비 매우 적은 비율로 발생합니다.

1.2 본 시스템이 하는 일

과거 데이터(적발·등록·확정 등 타겟 정보가 있는 구간)로 지도학습 모델을 만든 뒤,

- 각 사업 건에 위험도 점수(0~1,000)를 부여하고
- 라벨이 아직 없는 최신 데이터(추론)에도 같은 방식으로 점수를 적용합니다.

1.3 기대 효과

구분 / 효과

객관성 / 동일 규칙·동일 모델로 **재현 가능한** 우선순위

검증 / 평가(Test) 구간에서 **타겟 포착 품질**을 먼저 확인 후 추론에 적용

1.4 사용하는 학습 방법(알고리즘) — 개요

5종 알고리즘을 학습·비교합니다. 운영 기본은 RandomForest(주) + CatBoost(보조)입니다.

- RandomForest: 여러 결정나무의 다수결 → 주 운영·점수 기본
- Stacked Ensemble / EasyEnsemble / Gradient Boosting: 비교·참고용

2. 환경 구성 · 요구사항 · 주의사항

2.1 전체 구성(폴더)

,

LocalSubsidies_SupervisedLearning/ ← 프로그램·웹 UI (GitHub 가능)

└── scripts/ 파이프라인

└── RunWeb.bat 웹 서비스 실행

LocalSubsidies_ML_Data/ ← 데이터 전용 (프로젝트 밖·GitHub 금지)

|—— raw_inference/ 추론용 원본 CSV

|—— processed/ 전처리·분할 결과

|—— ops/ 운영 DB (ops.sqlite, raw 미포함)

,

핵심: 민감한 CSV·행단위 점수·모델은 항상 data_root(ML_Data) 쪽에만 둡니다.

2.2 PC 요구사항 (사양에 따라 작업 능력이 달라짐)

웹 메뉴 「내 PC 사양 체크」로 본인 PC를 확인할 수 있습니다.

항목 / 쾌적 / 보통 / 부족 / 업무 영향

CPU 논리코어 / ≥8 / 4~7 / <4 / 학습·전처리 **수 시간~반나절** 소요

OS / — / Windows 10/11 64bit / — / macOS/Linux는 스크립트 수정 필요

같은 버튼을 눌러도 PC마다 걸리는 시간이 다릅니다.

- 쾌적: 5종 알고리즘 일괄 학습·평가 가능

- 부족: 알고리즘 2~3개만 선택 · 일괄 실행 지양

개발·검증에 사용된 참고 사양: Ryzen 3 3200G, RAM 약 14GB — 보통~부족 경계 수준입니다.

2.3 raw 데이터 관리 방안 (필독)

왜 중요한가

raw CSV에는 사업·기관 정보와 식별에 해당할 수 있는 컬럼이 포함될 수 있습니다.

권장 원칙

원칙 / 설명

****GitHub 금지**** / raw·점수·모델·ops.sqlite ****커밋·업로드 금지****

****웹은 로컬만**** / 주소는 ****127.0.0.1**** 만 사용 (0.0.0.0·터널·클라우드 배포 금지)

****백업·접근 통제**** / USB·공유폴더·동기화 클라우드에 raw 올릴 때 ****암호화·권한**** 검토

학습용 vs 추론용 raw

폴더 / 용도 / 타겟(TAET_YN 등)

`raw\_inference/` / **추론**(미지 데이터) / 없어도 됨 — 시스템이 무시

스키마는 TLS4902R_Layout 기준으로 동일 레이아웃입니다.

2.4 소프트웨어 설치 (최초 1회)

1. Python 3.10+ 설치 (Windows 64bit)

`

.venv\Scripts\activate

`

`

`

4. data_root 아래 raw/, raw_inference/ 폴더 생성

2.5 주의사항 요약

- 브라우저 주소는 http://127.0.0.1:8501 (또는 콘솔에 표시된 포트)

- 코드 수정 후에는 RunWeb.bat 재시작 후 사용

- 과금되는 외부 API-클라우드 없음 — 전기·본인 PC만 사용

3. 웹 서비스 구동 방법

3.1 실행 (일상)

1. configs/local.yaml 의 data_root 확인

3. 브라우저에서 http://127.0.0.1:8501 접속 (자동 열림 가능)

3.2 종료

- RunWeb.bat 콘솔 창을 닫으면 서버 종료

3.3 터미널 실행 (선택)


`

.\venv\Scripts\activate

`

4. 전반 업무 순서 (웹 기준 · 모든 케이스)

4.1 큰 그림



4.2 A. 학습·평가 — 정상 흐름

→ 학습 파이프라인

→ 04 누수점검 —PASS—→ 05 학습 (2종 이상 선택)

→ 08 모델순위 → 09 리포트 → 10 타겟 포착 분포

→ 타겟 포착 분포 (Test: 포착 품질 확인)

4.3 A-예외. 04 누수점검 FAIL

→ 제외할 피처 선택

→ 03 전처리 → 04 재실행

누수: 모델이 “정답을 미리 아는” 컬럼을 학습하면 점수가 비현실적으로 좋아집니다. 반드시 PASS 후 학습.

4.4 A-예외. 05 학습 중단·재실행

→ RunWeb.bat 재실행

→ 상단 배너·Run 이력에서 상태 확인

4.5 B. 추론 — 운영 흐름

,

→ 데이터 등록(raw_inference 업로드)

→ 추론 → 결과 확인

· Excel 생성 → ops_queue_inference.xlsx

,

6월 데이터가 나중에 들어오는 경우: CSV 추가 후 11 추론 재실행 (1~6월 통합 재산출).

4.6 케이스별 “어디서 멈추고 무엇을 보나”

상황 / 다음 행동 / 확인 메뉴

모델이 없음 / 05까지 실행 / 모델 비교·평가

점검 기준 검증 / 10 완료 후 / 타겟 포착 분포

PC가 느림 / 알고리즘 줄여 05 / 내 PC 사양 체크

5. 메뉴별 설명 (웹)

메뉴 / 설명

****데이터 등록**** / 학습용 `raw/` · 추론용 `raw\_inference/` CSV 업로드 · 등록 목록·삭제

↳ ****학습 파이프라인**** / 01~10 단계 실행 · 분할(기간/랜덤) · 알고리즘 다중 선택 · 일괄 Job · 누수 FAIL 재개

↳ ****타겟 포착 분포**** / ****Test(평가) 전용**** — 전체 4x4 + ****실제 타겟 분포****로 포착 품질 확인

↳ ****추론 실행**** / 11 추론 Job · 라벨 컬럼 자동 무시

****Run 이력**** / 과거 run_id별 단계 상태·순위·집계

****사용자 가이드**** / 요약 문서·PDF 다운로드

상단 전역 배너: 실행 중 Job 이름·진행률·취소 버튼.

6. 학습·평가 vs 추론 — 차이와 업무 활용

6.1 한 줄 비교

****학습·평가** / **추론****

****목적** / 모델 만들기 · **얼마나 잘 맞는지 검증** / **앞으로 점검할 건** 고르기**

****대표 산출** / 모델 파일 · Test 점수 · 타겟 포착 분포 / inference 점수 · **점검 우선순위표****

6.2 점검 우선순위 규칙 (공통 개념)

주 모델·보조 모델 각각 점수 상위% 로 A~D 구간을 나눕니다.

구간 / 의미

****B**** / 1% 초과 ~ 5%

****D**** / 10% 초과

4×4 우선순위(1~16): 주등급이 먼저, 같은 주등급 안에서 보조등급 순.

6.3 업무 활용 예시

예시 1 — 연 1회 모델 갱신 (학습·평가)

> 2024~2025년 적발·등록 데이터로 모델을 학습하고, 2025년 하반기 Test로 성능을 확인한다.

1. raw/에 학습용 CSV 배치

3. 모델 비교·평가에서 RandomForest·CatBoost 순위 확인

5. PASS·성능 만족 시 → 이 모델을 추론에 사용

예시 2 — 분기별 선제 점검 (추론)

> 2026년 1~5월 데이터는 아직 적발 결과가 없다. 위험도가 높은 사업부터 점검 계획을 세운다.

1. raw_inference/에 202601~202605 CSV

3. 결과 확인 → 우선순위 1~5위 Excel 추출

5. 6월 CSV 확보 후 → 추론 재실행해 명단 갱신

예시 3 — 주·보조 불일치 건 처리

> 주 모델은 A구간인데 보조는 D구간인 건이 있다.

- 의미: 한 모델만 고위험 — 과탐 또는 애매한 건 가능

- 반대로 주A×보A(우선순위 1) 는 최우선 점검 후보

예시 4 — PC가 느린 팀

> RAM 8GB PC에서 5종 전체 학습이 실패한다.

1. 내 PC 사양 체크 → 부족 확인

3. 추론도 동일 2종만 실행 — 운영 기본(주·보) 에 충분

6.4 산출 파일 위치 (로컬 · GitHub 금지)

구분 / 경로 예시

추론 점수 / `{data\_root}/algorithms/{algo}/scores/inference/`

추론 점검 우선순위 / `{data\_root}/algorithms/operations/ops\_queue\_inference.xlsx`

7. 문의·추가 문서

문서 / 내용

docs/web_local.md / 로컬 웹·Job·보안 원칙

docs/metrics_guide.md / PR-AUC·리프트 등 지표 해설

본 PDF는 일반 소개용입니다. 상세 수치·컷오프 변경은 operations_criteria.md 및 현장 규정을 따르세요.